Escuela Politécnica Nacional

Facultad De Ingeniería En Sistemas



Fundamentos de Big Data

Manual de Instalación, Configuración y Replicabilidad

Proyecto: Análisis de Fallecidos por Accidentes de Tránsito en Ecuador (SPPAT 2016–2021) — Fase ETL

Integrantes:

Esteban López

Samuel Crespo

Matías Lamiña

John Durán

Paralelo: GR1CD

13 de Noviembre del 2026

1. Descripción General de la Arquitectura e Infraestructura

Para garantizar la escalabilidad, portabilidad y reproducibilidad del pipeline ETL (Extracción, Exploración y Transformación) sin depender de configuraciones complejas de hardware local, se implementó una arquitectura desacoplada basada en servicios en la nube:

- **Capa de Almacenamiento (Repositorio / Data Lake):** Alojamiento del conjunto de datos crudo en GitHub (raw.githubusercontent.com), permitiendo su ingesta directa mediante peticiones HTTP/HTTPS desde cualquier entorno de ejecución sin depender de rutas locales.
- **Capa de Procesamiento y Cómputo:** Entorno gestionado en la nube mediante Google Colaboratory con motor de ejecución Python 3 (máquina virtual Linux), complementado con compatibilidad total para entornos locales (Jupyter Notebook / VS Code).
- **Stack Tecnológico (Librerías de Ciencia de Datos):** pandas (ingesta CSV, inspección de esquemas, limpieza y exportación), numpy (manejo vectorizado y valores nulos), matplotlib y seaborn (visualización estadística exploratoria).

2. Enlaces Directos de Descarga y Contenido del Paquete (.zip)

Todos los recursos necesarios para auditar y reproducir el flujo de datos se encuentran disponibles en los siguientes enlaces públicos y adjuntos dentro de este paquete comprimido:

Recurso / Artefacto	Enlace Directo / Archivo Adjunto
Repositorio Oficial (GitHub)	https://github.com/johnprogra25/proyecto-big-data-sppat
Dataset Original Crudo (16,526 registros)	https://raw.githubusercontent.com/johnprogra25/proyecto-big-data-sppat/main/sppat_fallecidosaccidentestransito_2016-2021.csv
Cuaderno Interactivo (Google Colab)	https://colab.research.google.com/drive/1Z1LYqCywnBZsG2lAHXVUH5oN8iGdAAdq

Archivos incluidos en la entrega (.zip):

- **Manual_Instalacion_y_Replicabilidad.docx:** Este documento técnico con la guía de configuración, diccionario de datos e instrucciones.
- **Proyecto_Bimestral.ipynb:** Cuaderno de Google Colab / Jupyter con el código documentado, métricas y gráficos.
- **sppat_fallecidosaccidentestransito_2016-2021.csv:** Conjunto de datos crudo original (16,526 filas y 10 columnas).
- **sppat_fallecidos_accidentes_limpio.csv:** Conjunto de datos resultante tras la limpieza, estandarización y filtrado.

3. Requisitos e Instalación del Entorno

Opción A: Ejecución en la Nube (Google Colaboratory — Recomendado)

No requiere instalación local de software ni configuración de variables de entorno, ya que el runtime de Google Colab incluye preinstaladas todas las dependencias necesarias (Python 3, pandas, numpy, matplotlib y seaborn).

Opción B: Instalación y Configuración en Entorno Local (Windows / Linux / macOS)

Si desea replicar el entorno en una computadora local, siga estos pasos:

- **1. Instalar Python:** Contar con Python 3.8 o superior instalado en el sistema.
- **2. Crear y activar un entorno virtual (recomendado):** Aísla las dependencias del proyecto para evitar conflictos de versiones.

```
python                          -m                          venv                          env_etl
#                                       En                                          Windows:
env_etl\Scripts\activate
#                    En                    Linux                    /                    macOS:
source env_etl/bin/activate
```

- **3. Instalar las librerías requeridas mediante pip:**

```
pip install pandas numpy matplotlib seaborn jupyter
```

4. Puntos Clave de Configuración Técnica

Para asegurar la integridad de los datos y evitar errores al reproducir el pipeline, se establecieron las siguientes configuraciones críticas:

- **Codificación de Entrada (encoding='latin-1'):** El CSV crudo del SPPAT contiene caracteres propios del español (tildes y letra 'ñ' en provincias como Sucumbíos, Manabí, Cañar y cantones como Shushufindi). Es indispensable mantener encoding='latin-1' en pd.read_csv().
- **Codificación de Salida (encoding='utf-8'):** El dataset limpio final (sppat_fallecidos_accidentes_limpio.csv) se exporta en UTF-8 sin columna de índice (index=False) para facilitar su ingesta en motores Big Data, bases de datos SQL o herramientas BI.
- **Normalización Categórica Segura:** Los campos de texto se estandarizan a mayúsculas y sin espacios residuales (.strip().upper()), preservando los valores nulos reales (NaN) antes del filtrado.
- **Parseo Temporal (errors='coerce'):** La variable Fecha Siniestro se convierte a tipo datetime64 para derivar la columna Anio_Siniestro y realizar el agrupamiento anual.

5. Guía Paso a Paso para Reproducir el Flujo ETL

5.1. Ejecución en Google Colab

- **Paso 1:** Suba el archivo Proyecto_Bimestral.ipynb a Google Drive y ábralo con Google Colaboratory.
- **Paso 2:** En el menú superior, seleccione Entorno de ejecución > Reiniciar sesión y ejecutar todo.

- **Paso 3:** Verifique la ejecución secuencial de las 4 etapas: (1) Extracción de los 16,526 registros desde GitHub, (2) Exploración con 4 análisis cuantitativos y gráficos, (3) Transformación/limpieza de texto y nulos, y (4) Exportación del archivo sppat_fallecidos_accidentes_limpio.csv en el panel izquierdo de archivos.

5.2. Ejecución en Modo Local / Offline (sin conexión a Internet)

- **Paso 1:** Descomprima el archivo .zip en una carpeta local.
- **Paso 2:** Abra Proyecto_Bimestral.ipynb en Jupyter Notebook o VS Code.
- **Paso 3:** En la celda de Extracción, sustituya la URL remota por el nombre del archivo local adjunto:

```
URL = "sppat_fallecidosaccidentestransito_2016-2021.csv"
```

- **Paso 4:** Ejecute todas las celdas (Run All) para regenerar los gráficos y el CSV limpio.

6. Diccionario de Datos (Esquema del Dataset)

#	Nombre del Campo	Tipo	Descripción
1	**No.**	int64	Identificador secuencial único del registro.
2	**Género de la víctima**	string	Sexo registrado de la víctima (MASCULINO, FEMENINO).
3	**Estado Civil de la víctima**	string	Situación conyugal registrada (SOLTERO/A, CASADO/A, etc.).
4	**Condición**	string	Rol de la víctima en el evento vial (PEATÓN, OCUPANTE, etc.).
5	**Fecha de muerte Víctima**	object	Fecha oficial registrada del fallecimiento.
6	**Tipo de accidente**	string	Clasificación del siniestro (CHOQUE, ATROPELLO, VOLCAMIENTO, CAIDA).
7	**Fecha Siniestro**	datetime64	Fecha en la que ocurrió el accidente de tránsito.
8	**Cantón**	string	Cantón del Ecuador donde ocurrió el siniestro.
9	**Provincia**	string	Provincia del Ecuador donde ocurrió el siniestro.
10	**Fecha de creación de Protección...**	object	Fecha de creación del trámite de cobertura en el SPPAT.
11	**Anio_Siniestro (Generada)**	int32	Año extraído de Fecha Siniestro durante el análisis temporal.